



Alucinaciones de la inteligencia artificial: impacto en tecnología, política y sociedad

Hallucinations of artificial intelligence: impact on technology, politics, and society

Cristian David Barría Huidobro 

Universidad Mayor de Chile

CITACIÓN APA:

Barría Huidobro, C. D. (2024). Alucinaciones de la inteligencia artificial: impacto en tecnología, política y sociedad. *Revista Estrategia Poder y Desarrollo*, 3(5), 47-64.

<https://dx.doi.org/10.25062/2955-0289.4847>



Publicado en línea: **Junio 30 de 2024**



[Enviar un artículo a la Revista](#)



Los artículos publicados por la *Revista Estrategia, Poder y Desarrollo* son de acceso abierto bajo una licencia *Creative Commons*:
[Atribución - No Comercial - Sin Derivados](#).

Alucinaciones de la inteligencia artificial: impacto en tecnología, política y sociedad

Hallucinations of artificial intelligence: impact on technology, politics, and society

DOI: <https://dx.doi.org/10.25062/2955-0289.4847>

Cristian David Barriá Huidobro 

Universidad Mayor de Chile

Resumen

La inteligencia artificial se ha convertido en la principal protagonista del desarrollo tecnológico de los últimos años, experimentando avances vertiginosos que le han permitido integrarse en diversos aspectos de la vida humana. La capacidad de una IA para entregar al usuario exactamente lo que necesita es un factor fundamental para que soluciones que emplean estas tecnologías puedan masificarse y formar parte del día a día humano. No obstante, el contenido generado por una IA puede incorporar alteraciones que produzcan resultados imprecisos o incluso falsos. Este fenómeno conocido como alucinaciones de la IA representa importantes desafíos para el desarrollo de estas tecnologías y genera impactos políticos, económicos, reputacionales y personales, entre otros.

Palabras Clave: alucinaciones de la inteligencia artificial; alucinaciones humanas; desarrollo tecnológico; inteligencia artificial; tecnología

Artificial intelligence has become the leading force in technological development in recent years, undergoing rapid advancements that have allowed it to integrate into various aspects of human life. An AI's ability to provide users with exactly what they need is a fundamental factor for solutions employing these technologies to become widespread and part of human daily life. However, the content generated by an AI can incorporate alterations that produce inaccurate or even false results. This phenomenon, known as AI hallucinations, presents significant challenges for the development of these technologies and generates political, economic, reputational, and personal impacts, among others.

Key words: AI hallucinations, artificial intelligence, human hallucinations, technological Development, technology

Abstract

Artículo de reflexión

Recibido: 5 de mayo de 2024 • Aceptado: 12 de junio de 2024

Contacto: Cristian David Barriá Huidobro  cristian.barría@umayor.cl



Introducción

El desarrollo de la inteligencia artificial (IA) ha experimentado un rápido avance en los últimos años, transformando diversos aspectos de la sociedad humana mediante su capacidad para generar o transformar contenido de diversa índole. Desde la simulación de conversaciones humanas hasta la identificación y clasificación de elementos mediante cámaras de vigilancia, pasando por la detección automatizada de *malware* complejo, el reconocimiento de comportamientos atípicos en redes corporativas, la mejora de la calidad de imágenes o pistas de audio y el análisis predictivo, entre un sinfín de ejemplos (West & Allen, 2018).

Como ha ocurrido con otros procesos tecnológicos disruptivos, la IA ha estado involucrada, ya sea directa o indirectamente, en fenómenos de diversa naturaleza. Algunos de estos fenómenos son las denominadas *alucinaciones de la IA*, instancias en las cuales el contenido generado por alguna IA presenta elementos o patrones inesperados. Cuando el resultado incluye algún tipo de alteración diferente de lo esperado, estas pueden variar desde leves imprecisiones hasta falsedades completas. Las causas de una alucinación de IA pueden ser variadas, incluso por modificaciones intencionales, evidenciando las complejas interacciones entre los algoritmos de aprendizaje de máquina, los sesgos en las bases de datos usadas para alimentar la IA y las motivaciones de los usuarios humanos. Además, se relacionan con los procesos habituales de la IA (Rawte et al., 2023), tales como la adquisición de datos, el preprocesamiento de datos y el entrenamiento de modelos, entre otros.

Estas alucinaciones plantean serias interrogantes sobre las capacidades y limitaciones de la IA para generar contenido que imite el producido por un ser humano. Del mismo modo, subrayan la necesidad de identificar los riesgos asociados con la generación y distribución de contenido alterado, así como desarrollar la capacidad para detectar a tiempo estos contenidos (Li, 2023; Hatem et al., 2023).

Similar al impacto que tuvo internet en la vida cotidiana de las personas, la IA sigue integrándose cada vez más en nuestras actividades diarias. Por lo tanto, el impacto de estas alucinaciones será cada vez más significativo, lo que motiva un debate creciente sobre aspectos éticos, de gobernanza y de responsabilidad en relación con el desarrollo de la IA.

En este estudio, abordamos los conceptos generales que constituyen las bases de las alucinaciones de la IA en el aprendizaje automático, así como sus diferencias con los fenómenos alucinatorios humanos. Destacamos los desafíos específicos asociados con las alucinaciones de la IA y los contenidos que generan. Nuestro objetivo es establecer un marco de trabajo para el estudio, comprensión y análisis de estos fenómenos en el ámbito de la IA.

Marco teórico

El panorama conceptual en torno de las alucinaciones de la IA abarca una exploración interdisciplinaria de las arquitecturas de redes neuronales, metodologías de entrenamiento de IA y perspectivas de las ciencias cognitivas en la generación de contenido artificial. En el corazón de las alucinaciones de la IA, se encuentran los modelos de aprendizaje profundo, como las redes neuronales recurrentes (RNN), las redes de memoria a corto y largo plazo (LSTM) y las arquitecturas basadas en transformadores como GPT (Transformador Generativo Pre-Entrenado).

Estas arquitecturas de redes neuronales están diseñadas para procesar datos secuenciales, como texto, mediante el aprendizaje de representaciones jerárquicas del lenguaje. Durante su entrenamiento, estos modelos son expuestos a grandes cantidades de datos de texto, lo que les permite capturar patrones estadísticos y relaciones semánticas inherentes al lenguaje en cuestión, como el reconocimiento de voz, recomendaciones de contenidos y traducción automática, entre otros. Sin embargo, la complejidad de estos modelos también puede dar lugar a conductas inesperadas, incluidas las alucinaciones de la IA, donde los modelos producen resultados de texto nuevos y a veces inverosímiles (Lee et al., 2018).

Las metodologías de entrenamiento empleadas en el aprendizaje profundo desempeñan un papel fundamental a la hora de moldear las conductas de los modelos de IA e influir en la aparición de resultados alucinatorios. Técnicas como el preentrenamiento sin supervisión, el ajuste de tareas específicas y el aumento de datos contribuyen a la diversidad y riqueza del contenido generado por IA. No obstante, estas metodologías también pueden introducir sesgos y artefactos que, como cualquier tipo de error, afectan la calidad y fiabilidad de los resultados producidos por los modelos de IA (Ji et al., 2023).

Desde la perspectiva de la ciencia cognitiva, las alucinaciones de la IA pueden compararse con algunas distorsiones observadas en la cognición humana. Al igual que nuestra percepción puede ser influenciada por procesos cognitivos internos y estímulos externos, los sistemas de IA emplean entradas externas, como instrucciones de texto, y mecanismos internos, como algoritmos y representaciones aprendidas del lenguaje, para interpretar los datos con que deben trabajar y producir una salida. La aparición de alucinaciones en este contexto computacional expone los desafíos que implica acortar la brecha entre el aprendizaje estadístico y la comprensión semántica.

Definiciones

Las alucinaciones de la IA pueden definirse como desviaciones de los resultados esperados en el contenido generado por un sistema de inteligencia artificial (IA), caracterizadas por la introducción de elementos de imaginación o sin sentido durante la producción de

dicho contenido (Merriam-Webster, s.f.). En el contexto del procesamiento del lenguaje natural (NLP) y el aprendizaje de máquina, estas alucinaciones representan patrones inesperados o artefactos que emergen durante el proceso de creación del contenido de un modelo de IA, según lo expuesto por Ji et al. (2023).

Es crucial diferenciar entre las alucinaciones de inteligencia artificial (IA) y las alucinaciones humanas. En términos etimológicos, la palabra *alucinación* proviene del latín *'hālūcīnor'*, que significa "divagar mentalmente" o "soñar" (Olivetti, s.f.). Desde la perspectiva de la psiquiatría, la alucinación se entiende como: "Una percepción sensorial falsa, en la ausencia de un estímulo externo real".

Las alucinaciones humanas suelen estar asociadas con condiciones neurológicas, estados alterados de la conciencia o trastornos de salud mental, mientras que las alucinaciones (Siegel, 1977) de la IA son fenómenos computacionales que resultan de algoritmos complejos y sesgos presentes en las bases de datos de entrenamiento.

Las alucinaciones de la IA suelen ser no intencionales y surgen debido a diversos factores inherentes a los sistemas de aprendizaje. Estos incluyen el diseño de la arquitectura de una red neuronal computacional, la calidad y diversidad de los datos de entrenamiento y los objetivos de optimización utilizados durante el proceso de aprendizaje del modelo. Puesto que los modelos "aprenden" a generar contenido basándose en patrones estadísticos detectados en los datos, ocasionalmente pueden producir resultados que se desvían de las normas lingüísticas esperadas (Dziri et al., 2022).

Cabe destacar que si bien las alucinaciones de la IA esencialmente representan un desvío del objetivo esperado, no son inherentemente negativas, ya que nos proporcionan información sobre el funcionamiento interno de los modelos de IA y las complejidades subyacentes de la generación del lenguaje. Además, existen escenarios en los que puede ser útil producir intencionalmente una alucinación en la IA y explorar resultados creativos diferentes a aquellos considerados "correctos", lo que limitaría el descubrimiento de otras posibilidades. Esto puede ser especialmente útil cuando se utiliza la IA en el arte y otros contextos donde la creatividad sea un factor deseable (IBM, 2024). No obstante, mitigar la ocurrencia de alucinaciones es crucial para potenciar la confiabilidad y precisión del contenido generado por IA en aplicaciones del mundo real.

Cuestionamientos relevantes

Considerando las diversas instancias del quehacer humano y tecnológico en las cuales la IA ya se está integrando, y entendiendo las alucinaciones de la IA como desviaciones de los resultados legítimos esperados, es pertinente preguntarse:

- ¿Qué impacto pueden tener las alucinaciones de la IA en la sociedad?
- ¿Cómo puede determinarse si un contenido específico es producto de una alucinación de IA?

Antecedentes generales

Aunque la IA puede considerarse una disciplina joven en comparación con la filosofía o las matemáticas, lo cierto es que este campo del conocimiento representa décadas de investigación, innovación y avances tecnológicos que han revolucionado el mundo moderno. Con raíces que se remontan a mediados del siglo XX (Muthukrishnan et al., 2020), la idea de lograr la creación de máquinas inteligentes capaces de emular habilidades cognitivas humanas ha sido el motor detrás de la investigación en IA, impulsando importantes descubrimientos tecnológicos y cambios de paradigma en el ámbito.

Los orígenes de la IA pueden rastrearse hasta el trabajo de pioneros como Alan Turing, quien propuso el concepto de una máquina de cómputo universal capaz de simular cualquier proceso algorítmico. Su trabajo sentó las bases de la computación moderna, lo cual, a su vez, impulsó las fases más tempranas de la investigación en el campo de la IA.

Durante las décadas de 1950 y 1960, el ámbito de la IA experimentó un rápido crecimiento, impulsado por el optimismo y entusiasmo respecto del potencial uso de computadoras para emular la inteligencia humana. La Conferencia de Dartmouth (1956), organizada por John McCarthy, Marvin Minsky, Nathaniel Rochester y Claude Shannon, es considerada la cuna de la IA, al establecer formalmente el campo y estructurar la agenda para su investigación futura (Buchanan, 2005).

Durante este periodo, la investigación se centró en el desarrollo de sistemas simbólicos de IA, también conocidos como *Good Old-Fashioned AI* (GOFAI) (Haugeland, 1989), los cuales dependían de manipulaciones simbólicas y razonamiento lógico para resolver problemas. Las primeras versiones de programas de IA, como Logic Theorist (Gugerty, 2006) y General Problem Solver (GPS) (Newell & Shaw, 1959) demostraron la viabilidad del enfoque simbólico para tareas como la comprobación de teoremas y la resolución de puzzles.

No obstante, las limitaciones de la IA simbólica se hicieron evidentes a medida que los investigadores enfrentaban desafíos al tratar de escalar los sistemas para manejar complejidades e incertidumbres a nivel del mundo real. En las décadas de 1970 y 1980, el interés en la IA experimentó una marcada disminución, lo que condujo al denominado *invierno de la IA*, tiempo caracterizado por una reducción en la financiación, escepticismo y, en general, un estancamiento en el campo (Floridi, 2020).

El resurgimiento de la IA en la década de 1990 fue impulsado por los avances en el aprendizaje automático (*machine learning*, ML), las redes neuronales y la capacidad

de cómputo. Además, el desarrollo de técnicas y mecanismos como los algoritmos de retropropagación para entrenar redes neuronales artificiales, junto con un progreso significativo en *hardware* y la disponibilidad de datos, revolucionó el campo de la IA y allanó el camino a nuevos enfoques para modelar y aprender de los datos (Fradkov, 2020).

El surgimiento de internet y la proliferación de las tecnologías digitales en el siglo XXI aceleraron aún más el ritmo de la innovación en IA, dando lugar a la aparición de nuevos paradigmas, como el aprendizaje profundo (también conocido como *deep learning* o *DL*, aunque el término fue acuñado en los años 1980), el aprendizaje reforzado y el procesamiento del lenguaje natural. Los avances posteriores en diversas aplicaciones, como el reconocimiento de imágenes, la síntesis de lenguaje, los sistemas de conducción autónoma de vehículos y los asistentes virtuales, entre otros, transformaron industrias y sociedades completas (Schmidhuber, 2022; Dechter, 1986).

En términos concretos, la IA representa la búsqueda de algoritmos, metodologías y tecnologías que permitan a las máquinas percibir, razonar, aprender y actuar de forma autónoma en diversos contextos. En este punto, es importante destacar la relevancia del aprendizaje automático (*machine learning*, *ML*) para el desarrollo de la IA, ya que proporciona el marco computacional para habilitar sistemas capaces de aprender por medio de los datos y mejorar su eficacia en la resolución de tareas a lo largo del tiempo.

Los algoritmos de ML utilizan técnicas estadísticas para identificar patrones y relaciones y adquirir conocimiento a partir de grandes conjuntos de datos, lo que permite a las máquinas realizar predicciones, tomar decisiones y generar recomendaciones sin necesidad de una programación explícitamente escrita para tales efectos.

Uno de los aspectos clave del aprendizaje automático (*machine learning*, *ML*) es su capacidad de adaptación y optimización mediante el aprendizaje iterativo de datos. Los algoritmos de ML ajustan sus parámetros internos de manera iterativa con base en los datos recibidos, mejorando gradualmente su rendimiento en la realización de tareas específicas a medida que adquieren experiencia. Esta capacidad de aprendizaje basado en datos distingue el ML de los enfoques tradicionales de programación basados en reglas definidas, lo que permite a los sistemas manejar eficientemente tareas complejas en contextos inciertos. En general, el ML puede clasificarse en tres tipos principales (Sah, 2020):

Aprendizaje supervisado

Implica entrenar algoritmos de ML con conjuntos de datos etiquetados, donde cada entrada está asociada con una salida correspondiente o una variable objetivo. Esta metodología se asemeja a un profesor que proporciona ejemplos y respuestas a sus estudiantes, lo que les permite aprender a mapear entradas con salidas. Las tareas típicas del aprendizaje supervisado incluyen:

Clasificación

El algoritmo predice etiquetas discretas o categorías para nuevas entradas, con base en patrones aprendidos de los datos de entrenamiento. Por ejemplo: identificación de imágenes (detectar elementos en archivos de imagen), análisis de sentimientos (determinar si un texto es positivo o negativo) y detección de correo no deseado (clasificar correos como *spam* o no *spam*).

Regresión

El algoritmo predice valores numéricos continuos para nuevas entradas, con base en patrones aprendidos previamente. Entre las aplicaciones prácticas de estas tareas, encontramos la predicción de valores inmobiliarios basada en características como tamaño y ubicación y la proyección de precios en la bolsa de valores basándose en datos históricos, entre otros ejemplos.

Aprendizaje no supervisado

Similar al caso anterior, en este enfoque los conjuntos de datos utilizados para el aprendizaje no poseen etiquetas, ni en la entrada ni en la salida de los datos. Sin guía ni supervisión, el objetivo es descubrir patrones, estructuras o relaciones ocultas entre los datos sin conocimiento previo de la salida. Algunos ejemplos comunes de tareas de aprendizaje no supervisado incluyen:

Agrupamiento o clustering

El algoritmo agrupa puntos de datos similares basándose en sus características o atributos inherentes. Ejemplos de tareas incluyen el agrupamiento de promedios K (o *K-means clustering*), agrupamiento jerárquico y agrupamiento basado en densidad.

Reducción de dimensionalidad

Este tipo de técnicas tienen como objetivo reducir la complejidad de un conjunto de datos mediante la extracción de un conjunto menor de características que contienen la mayoría de la información de interés. El análisis de componentes principales (PCA), el modelo t-SNE (*t-distributed stochastic neighbor embedding*) y la descomposición de valores singulares (SVD) son métodos populares para la reducción de dimensionalidad.

Aprendizaje reforzado

El agente aprende a interactuar con un ambiente realizando acciones y recibiendo retroalimentación o recompensas. El objetivo es aprender una política o estrategia que maximice las recompensas acumulativas a lo largo del tiempo.

Aprendizaje de políticas

El agente explora el ambiente al tomar acciones, recibe retroalimentación (ya sean recompensas o sanciones) y actualiza su propia política teniendo en cuenta los resultados observados. En este tipo de aprendizaje, encontramos el *Q-Learning*, las Redes Profundas de *Q-Learning* (*DQN*) y los métodos de gradiente de políticas.

Aprendizaje de valores

Se centra en estimar las recompensas acumulativas esperadas asociadas con un estado particular y una acción específica. Algoritmos como el aprendizaje por diferencias temporales (TD) tienen como objetivo aproximar la función de valor, que representa las recompensas futuras esperadas para cada par de estado-acción. Este tipo de aprendizajes son útiles para tareas como el control, la planificación y la toma de decisiones óptimas en entornos dinámicos.

Cada enfoque incorpora características específicas adecuadas para abordar diferentes tipos de tareas, por lo que los desarrolladores de IA deben planificar cuidadosamente qué tipo de aprendizaje automático emplearán en sus sistemas para lograr los niveles más altos posibles de efectividad. Dicho esto, las amplias aplicaciones de la IA están generando (y posiblemente seguirán generando) consecuencias legales, éticas y sociales que requieren atención tanto a nivel técnico como regulatorio y científico.

Alucinaciones de la IA y sus contrapartes humanas

Aunque ya hemos explorado la relación entre el mundo humano y el de la IA mediante el concepto de *alucinación*, cuando hablamos de acciones que causan efectos adversos de manera no intencional, surge una noción que, a pesar de tener una definición y uso formal, tiende a utilizarse informalmente como término despectivo: *estupidez*.

En 1976, el historiador italiano Carlo M. Cipolla publicó el ensayo "Le leggi fondamentali della stupidità umana" (Las leyes básicas de la estupidez humana, en italiano), donde explora el concepto de estupidez y formula cinco leyes generales (Cipolla & Altan, 2015).

Para Cipolla, la estupidez humana se refiere a una conducta que causa perjuicio a otros sin generar ningún beneficio propio, a diferencia de la delincuencia, por ejemplo, donde normalmente se busca obtener algún tipo de beneficio (dinero, poder, etc.) mediante la perpetración de actos dañinos hacia terceros (robo y amenazas, entre otros). Es importante destacar que Cipolla no necesariamente se refiere a la baja inteligencia o a problemas cognitivos, sino más bien a la manifestación de comportamientos irracionales o poco reflexionados.

En este sentido, el punto en común entre la estupidez humana y las alucinaciones de la IA radica en algún tipo de efecto negativo generado por estos conceptos. Ahora

bien, al incorporar las cinco leyes de Cipolla, podemos considerar otros aspectos en la comparación.

Primera ley: Siempre e inevitablemente todos subestiman el número de individuos estúpidos en circulación

Esta ley señala una tendencia a pasar por alto la prevalencia de la estupidez en la sociedad. De manera similar, podría existir una tendencia a subestimar la frecuencia e impacto de los contenidos alucinatorios desarrollados por la IA. Al igual que las personas pueden ignorar el potencial de las conductas irracionales, los desarrolladores de IA podrían subestimar la ocurrencia de resultados inesperados o absurdos en los resultados producidos por la IA.

Segunda ley: La probabilidad de que una persona sea (o será) estúpida es independiente de cualquier otra característica de esa persona

Esta ley sugiere que la estupidez es indiscriminada y puede manifestarse en cualquier individuo, independientemente de su inteligencia, educación o antecedentes. En el contexto de la IA, las alucinaciones pueden ocurrir sin importar la sofisticación o complejidad del modelo de IA en cuestión, o la calidad de sus datos de entrenamiento. La probabilidad de encontrar resultados alucinatorios en los contenidos generados por IA se mantendría constante, sin importar otras características de estos sistemas o de sus desarrolladores.

Tercera ley: Una persona estúpida es aquella que causa pérdidas a otra persona o a un grupo de personas, sin obtener ninguna ganancia a cambio, e incluso puede ocasionar pérdidas para sí misma

Esta ley resalta el impacto perjudicial de la estupidez en otros sin beneficiar al perpetrador. En el contexto de las alucinaciones de la IA, los contenidos alucinatorios pueden causar confusión, desinformación y daño reputacional a individuos u organizaciones, sin proporcionar ningún beneficio tangible a la propia IA. Además, estos contenidos podrían resultar en costos de credibilidad, confianza y asignación de recursos para los sistemas de IA involucrados y sus desarrolladores.

Cuarta ley: La gente que no es estúpida siempre subestima el poder dañino de los individuos estúpidos. Ellos constantemente olvidan que, en cualquier momento y circunstancia, asociarse con gente estúpida puede implicar pérdidas costosas

De acuerdo con esta ley, existe una tendencia entre las personas que no son estúpidas a subestimar el potencial disruptivo de la estupidez y los costos asociados de las

interacciones establecidas con individuos estúpidos. Comparando con la IA, los desarrolladores podrían subestimar el impacto del contenido alucinatorio y los riesgos de depender del contenido generado por la IA sin una validación o escrutinio apropiado. Este tipo de errores podrían llevar a consecuencias costosas de diversa índole, ya sean económicas y reputacionales, entre otras.

Quinta ley: Una persona estúpida es el tipo más peligroso de persona

Esta ley establece que los individuos estúpidos representan la mayor amenaza para los demás, debido a su tendencia a causar daño sin mediar consecuencias. Por otro lado, un sistema de IA propenso a las alucinaciones puede ocasionar diversos riesgos para personas, organizaciones y sociedades. Como se mencionó, el contenido alucinatorio puede provocar desinformación, manipulación, malestar social y daños reputacionales o económicos. Esto resalta los riesgos asociados a la producción y difusión de este tipo de contenido sin supervisión. Sin embargo, ambas ideas poseen algunas diferencias importantes. En primer lugar, la estupidez humana deriva de la conducta irracional impulsada por diversos factores psicológicos y sociales, mientras que las alucinaciones de la IA involucran alteraciones en la interpretación y extrapolación de los datos aprendidos por el modelo. Por otro lado, la estupidez se asocia con acciones que ocasionan daño sin generar beneficio propio alguno (según Cipolla), mientras que las alucinaciones responden a sesgos en los datos de entrenamiento y desviaciones en el procesamiento de algoritmos complejos. Finalmente, las alucinaciones de la IA carecen de experiencia subjetiva o conciencia, en contraste con la estupidez humana, que implica conductas o toma de decisiones conscientes.

Alucinaciones de la IA: impacto en tecnología, política y sociedad

La aparición de alucinaciones en procesos y actividades que requieren servicios basados en IA tiene profundas implicaciones para el desarrollo tecnológico, ya que puede poner en tela de juicio la fiabilidad de la IA (Venkit et al., 2024). Estas alucinaciones representan un desafío significativo para el control de calidad de cualquier producto o servicio que implemente (o decida implementar) IA en sus procesos, ya que introducen una capa adicional de posibles fallos que deben ser identificados oportunamente. Esto implica el desarrollo de mecanismos y técnicas de detección que aún no están plenamente definidos, debido a que se trata de una problemática emergente.

Los procesos de validación de confiabilidad operativa también enfrentan un desafío similar. Además, la confianza que el usuario final pueda depositar en la IA se ve afectada. Asistentes virtuales, chatbots y herramientas de generación de contenido pueden

producir inadvertidamente resultados engañosos o sin sentido, lo que socava su utilidad y credibilidad en situaciones del mundo real.

En otra arista, las alucinaciones de la IA pueden contribuir a aumentar las preocupaciones que rodean las implicaciones éticas de las tecnologías de IA. La proliferación de desinformación resultante del contenido alucinatorio generado por IA puede exacerbar las divisiones sociales y afectar negativamente la confianza de la población en diversas fuentes de información. Este escenario plantea importantes interrogantes sobre la gobernanza, la auditabilidad y el uso responsable de las tecnologías de IA en sociedades democráticas.

Desde el punto de vista político, las alucinaciones de la IA introducen nuevas complejidades en el panorama informativo, donde discernir correctamente entre hechos reales y ficción se vuelve cada vez más difícil. Actores malintencionados pueden aprovechar el contenido alucinatorio generado por IA para manipular la opinión pública, influir en los resultados electorales y sembrar discordia en la sociedad. Esto conlleva riesgos significativos para los procesos democráticos y destaca la necesidad de marcos regulatorios sólidos que mitiguen el impacto de la desinformación impulsada por IA.

En la sociedad, los efectos de las alucinaciones de la IA se extienden más allá de los ámbitos tecnológico y político, dando forma a percepciones culturales y normas sociales. La difuminación de la línea entre el contenido generado por humanos y por IA desafía las convenciones tradicionales de autoría, autenticidad y propiedad intelectual. Además, el contenido con elementos alucinatorios puede inadvertidamente perpetuar sesgos y estereotipos incorporados en los datos de entrenamiento, fortaleciendo las desigualdades sociales y exacerbando las divisiones.

Alucinaciones de IA y defensa

Como se ha analizado, el impacto de este tipo de alucinaciones abarca una variedad de posibilidades. Desde la perspectiva del sector Defensa, este fenómeno presenta un potencial multifacético, tanto de oportunidades, como de desafíos.

Campañas de desinformación

Existe la posibilidad de que el contenido alucinatorio sea utilizado como arma por adversarios o actores maliciosos para diseminar información falsa o alterada, ya sea dirigida a toda la sociedad de un país o enfocada en funcionarios y colaboradores del sector Defensa. Narrativas falsas, evidencias fabricadas y mensajes engañosos pueden ser propagados mediante contenido alucinatorio, generando confusión, sembrando desconfianza y creando o exacerbando posibles vulnerabilidades estratégicas.

Operaciones de ciberguerra y guerra psicológica

El contenido alucinatorio puede ser utilizado para manipular percepciones, afectar canales de comunicación o influir en la moral del adversario. Podría emplearse como una herramienta para fomentar la discordia entre el personal, manipular la opinión pública e influenciar los procesos de toma de decisiones en el contexto de seguridad y defensa.

Ataques dirigidos y explotación

Los sistemas de IA vulnerables al contenido alucinatorio podrían ser explotados por adversarios para lanzar ataques de diversos tipos contra infraestructura crítica y de la información, redes, sistemas, datos y usuarios. Actores maliciosos podrían aprovechar vulnerabilidades en los sistemas de IA para introducir información falsa, eludir medidas de seguridad y comprometer capacidades críticas de defensa que hagan uso directo o indirecto de la IA.

Mejora de conciencia situacional

Las tecnologías de IA también pueden ser utilizadas para detectar y mitigar el impacto del contenido alucinatorio en operaciones de defensa. La aplicación de algoritmos avanzados de IA, capaces de analizar grandes volúmenes de datos en tiempo real, podría ayudar a identificar y filtrar el contenido alucinatorio de aquel producido por fuentes legítimas. Esto mejoraría la conciencia situacional en general y los procesos de toma de decisiones.

Consideraciones legales y éticas

El posible uso de estas alucinaciones en operaciones de defensa plantea interrogantes sobre la responsabilidad legal de dichas acciones, así como sobre la transparencia y el cumplimiento de normas y convenciones internacionales. Las políticas y regulaciones relacionadas con el desarrollo y despliegue de tecnologías de IA en este ámbito deben abordar los riesgos y las implicaciones del contenido alucinatorio. Deben garantizar el cumplimiento de estándares éticos aplicables y el respeto de los derechos humanos.

La necesaria modernización de las instituciones armadas implica la integración de tecnologías de vanguardia que amplían y mejoran las capacidades estratégicas, tácticas y operativas de sus componentes tanto técnicos como humanos. Sin embargo, esto también conlleva la inclusión de nuevos riesgos y vulnerabilidades.

Caso de estudio: inyección intencional de alucinaciones en IA

Con el objetivo de demostrar la capacidad de generar alucinaciones en una IA, se utilizó la herramienta ChatGPT, un chatbot basado en IA que responde a preguntas ingresadas

por texto en una interfaz web. Además, se contó con tres herramientas web dedicadas a la detección de textos generados por IA para validar los contenidos elaborados por ChatGPT.

El proceso consistió en solicitar a ChatGPT un reporte ficticio sobre un tema específico y luego validar si las herramientas de detección eran capaces de identificar el contenido generado. Posteriormente, se realizó una iteración con ChatGPT para incluir intencionalmente diversos errores y sesgos que pudieran imitar aquellos atribuibles a una redacción humana. Cada iteración se sometió a los detectores y se registraron los resultados.

En la generación de contenido inicial, se solicitó al chatbot la elaboración de un reporte del clima para Santiago de Chile. La IA respondió creando una plantilla de reporte en lugar de proporcionar un ejemplo concreto:

Weather Forecast for Santiago de Chile
Date: [Current Date]
Today's Weather:
 - Temperature: [Current Temperature] °C
 - Conditions: [Clear/Sunny/Partly Cloudy/Cloudy/Rainy]
 - Precipitation: [Chance of Rain/Snow]
 - Wind: [Wind Speed] km/h, [Wind Direction]
Tomorrow's Forecast:
 - Temperature: [Forecasted Temperature] °C
 - Conditions: [Clear/Sunny/Partly Cloudy/Cloudy/Rainy]
 - Precipitation: [Chance of Rain/Snow]
 - Wind: [Wind Speed] km/h, [Wind Direction]
[Additional Details: UV Index, Humidity, Sunrise/Sunset Times, etc.]

Dado lo expuesto, se optó por utilizar datos ficticios de entre las opciones disponibles en la plantilla, y el reporte generado fue identificado correctamente en su totalidad por las herramientas de detección. A continuación, se solicitó un reporte que contuviera elementos alucinatorios.

Enchanted Weather Forecast for Santiago de Chile
Date: [Current Date]
Today's Magical Weather:
 - Temperature: [Current Temperature] °C (but feels like wandering through a mystical forest)
 - Conditions: [Clear/Sunny/Partly Cloudy/Cloudy/Rainy] (with a hint of fairy dust)
 - Precipitation: [Chance of Rain/Snow] (magic raindrops from a celestial realm)
 - Wind: [Wind Speed] km/h, [Wind Direction] (guided by the whispers of ancient spirits)
Tomorrow's Enchanted Forecast:
 - Temperature: [Forecasted Temperature] °C (as if basking in the glow of a phoenix)
 - Conditions: [Clear/Sunny/Partly Cloudy/Cloudy/Rainy] (with a touch of ethereal light)

- *Precipitation: [Chance of Rain/Snow] (showered by blessings from the heavens)*
- *Wind: [Wind Speed] km/h, [Wind Direction] (ushering in whispers of dreams from afar)*
- [Additional Details: UV Index, Humidity, Sunrise/Sunset Times, etc., with whimsical descriptions]*

A pesar de que el resultado coincide con las características de imprecisión y sinsentido que hemos comentado a lo largo del documento, esta primera iteración fue inmediatamente detectada por las herramientas. Por lo tanto, se procedió a solicitar una nueva iteración del texto alucinatorio, esta vez incluyendo opciones elegidas por la IA en lugar de utilizar una plantilla. Además, se buscó reducir el nivel de sinsentidos y mezclar datos realistas en el texto.

Enchanted Weather Forecast for Santiago de Chile

Date: April 5, 2024

Tomorrow's Enchanted Forecast:

- Temperature: 18°C (under the spell of a starlit sky)
- Conditions: Partly Cloudy (dancing with ethereal light)
- Precipitation: Chance of Rain (sprinkled with stardust from celestial realms)
- Wind: 15 km/h, North (whispering secrets of distant lands)

[Additional Details: UV Index, Humidity, Sunrise/Sunset Times, etc., with subtly whimsical descriptions]

Estos ajustes fueron suficientes para lograr que al menos uno de los servicios de detección no reconociera el texto como un producto de IA, demostrando así la factibilidad de generar alucinaciones intencionales que pueden incluso evadir sistemas de detección.

Si bien el ejemplo anterior es bastante simple, el potencial de explotación de este tipo de alucinaciones intencionales es considerable. Un ejemplo actual es el uso que estudiantes de diferentes niveles educativos hacen de las herramientas de IA para completar tareas sin la necesidad de realizar el estudio e investigación requeridos. Aunque el cuerpo docente podría emplear herramientas de detección para identificar estas prácticas poco éticas, el uso de alucinaciones intencionales en la IA podría contrarrestar estas medidas con relativa facilidad.

Identificación de alucinaciones de la IA

Durante el ejercicio práctico descrito en la sección anterior, el objetivo fue comprender el funcionamiento de las herramientas de detección de IA para dirigir las nuevas alucinaciones de manera que pudieran aumentar las posibilidades de lograr una evasión exitosa. Aunque en muchos casos se trata de *software* de código cerrado, lo que impidió examinar las estrategias directamente en el código, la literatura proporciona pautas generales que estas herramientas utilizan, ya sea empleando uno o varios mecanismos combinados (Xiao et al., 2024; Chen et al., 2023; Su et al., 2024; Luo et al., 2024).

Análisis estadístico

Consiste en la identificación de patrones y anomalías en los datos. En el caso del análisis de texto, se puede incluir el análisis de características lingüísticas como el vocabulario, la sintaxis y la semántica, para determinar la existencia de desviaciones en relación con los patrones del lenguaje natural. Para el contenido audiovisual, el análisis estadístico puede implicar la examinación de valores de píxeles, la distribución de colores y la frecuencia espectral, entre otros aspectos.

Fingerprinting de modelos

Hace referencia a la identificación de artefactos o sesgos característicos del modelo de IA en cuestión. Esta técnica puede incluir el análisis de la arquitectura del modelo, los sesgos en los datos de entrenamiento, o la generación de estos artefactos para efectuar un perfilamiento del contenido generado por un modelo específico.

Pruebas adversarias

Consiste en someter contenido a escrutinios diseñados para exponer vulnerabilidades o falencias en los resultados de IA. Por ejemplo, para contenido textual, se puede inyectar perturbaciones o modificaciones sutiles para provocar respuestas alucinatorias del modelo. Similarmente, para contenido audiovisual, se pueden agregar ruidos o distorsiones leves con la intención de inducir una conducta inesperada por parte de la IA.

Análisis conductual

Examen del comportamiento del contenido generado por IA por medio de diferentes contextos y dominios. Para contenido de texto, el análisis conductual puede incorporar análisis de coherencia semántica, consistencia lógica y relevancia contextual para identificar anomalías o desviaciones en comparación con textos escritos por humanos. Para imágenes o audios, pueden incluirse evaluaciones de pistas sonoro-auditivas para analizar los procesos de generación de contenido subyacentes o sesgos algorítmicos.

Análisis de metadatos

Este enfoque se centra en analizar los metadatos asociados al contenido en cuestión, como marcas temporales, información de autoría y parámetros de generación, para inferir la probabilidad del involucramiento de algún tipo de IA. Aunque los metadatos por sí solos pueden no ser concluyentes para identificar contenido de IA, la detección de anomalías o inconsistencias en ellos puede despertar sospechas y motivar una investigación más profunda utilizando otras técnicas.

Métodos de ensamble

Combinación de múltiples técnicas o modelos de detección para mejorar la robustez y precisión de los sistemas encargados de identificar contenido de IA. Gracias a esta capacidad de adaptación, los métodos de ensamble pueden abordar diferentes contextos y casos de uso con una mayor flexibilidad y consistencia que otras metodologías individuales.

Heurística de dominios específicos

Implica el uso de reglas o criterios diseñados especialmente para abordar un dominio de conocimiento particular y detectar contenido de IA relacionado con dicho dominio. Por ejemplo, en el análisis forense digital, una heurística de dominios específicos podría incluir la detección de artefactos o inconsistencias indicativas de manipulación de imágenes o videos mediante IA.

Puesto que la información técnica sobre los mecanismos empleados por los programas de detección de IA no siempre es pública, a veces no es posible determinar qué enfoque prefieren ciertas herramientas de detección. Sin embargo, el conocimiento existente sobre estos mecanismos permite tomar decisiones generales que puedan proponer contramedidas para eludir este tipo de sistemas, como se ilustró en la actividad práctica antes descrita. Asimismo, toda la información recopilada tras evasiones exitosas puede utilizarse como retroalimentación para desarrollar sistemas de detección más robustos.

Discusión: desafíos de las alucinaciones de la IA

El fenómeno de las alucinaciones de la IA presenta una serie de desafíos en diversos ámbitos, que incluyen aspectos tecnológicos, sociales, éticos y políticos. Desde el punto de vista tecnológico, uno de los principales obstáculos es la afectación al mundo del desarrollo de *software*. Ingenieros y desarrolladores de IA deben enfrentarse a los diferentes niveles de impredecibilidad de los contenidos generados por estas tecnologías. Las alucinaciones añaden incertidumbre adicional al proceso, lo que dificulta la planificación y ejecución de actividades que requieren un comportamiento predecible y estable. Esto se suma a los desafíos ya mencionados en otras secciones, como la carga adicional que estas alucinaciones representan para las tareas de aseguramiento de calidad y optimización de la experiencia del usuario, entre otros aspectos.

En cuanto a la detección de anomalías asociadas a estos procesos alucinatorios, aunque existen algunas técnicas que pueden utilizarse, es necesario un enfoque investigativo para mejorar las capacidades de identificación temprana del contenido alucinatorio. El entrenamiento adversario, la integración de validaciones del

tipo *human-in-the-loop* (HITL) y otros mecanismos de detección son ejemplos de herramientas existentes que contribuyen a mejorar la confiabilidad de los sistemas de IA en aplicaciones del mundo real.

En el ámbito geopolítico, los desafíos de las alucinaciones de la IA se entrelazan con discusiones más amplias sobre la guerra de la información y la competencia estratégica en la era digital. Los actores maliciosos pueden aprovechar el contenido de IA alucinatorio para difundir propaganda, manipular la opinión pública y socavar la confianza en las instituciones democráticas. En este sentido, la regulación del uso de la IA y la sanción del abuso de estas tecnologías dejan de ser preocupaciones políticas locales para convertirse en una necesidad de cooperación internacional evidente. Idealmente, esto conduciría al establecimiento de tratados y marcos normativos multinacionales, reduciendo así la posibilidad de lagunas legales que puedan socavar la capacidad sancionadora de los tribunales de diferentes países. Además, se evitaría la aparición de países con normativas regulatorias divergentes, similar a lo que sucede actualmente en el ámbito tributario con los llamados *paraísos fiscales*. En el contexto de la IA, una escasa colaboración internacional podría propiciar la existencia de paraísos regulatorios para el uso malicioso de la IA, lo cual podría ser explotado por delincuentes y otros actores.

Agradecimientos

El autor agradece a la Universidad Mayor de Chile su apoyo para la realización de este artículo.

Declaración de divulgación

El autor declara que no existe ningún potencial conflicto de interés relacionado con este artículo.

Financiamiento

El autor no declara fuente de financiamiento para la realización de este artículo.

Autor

Cristian David Barría Huidobro. Doctor en Ingeniería Informática con estudios postdoctorales en Alta Investigación en Educación Multicultural y Gestión de Redes Sociales. Magíster en Planificación y Gestión Educacional. Magíster en Ciencias de la Ingeniería Informática. Ingeniero en Informática. Licenciado en Informática. Director del Centro de Investigación en Ciberseguridad, Universidad Mayor, Chile.

Orcid: <https://orcid.org/0000-0002-5840-7407>

Contacto: cristian.barría@umayor.cl

Referencias

- Buchanan, B. G. (2005). A (very) brief history of artificial intelligence. *Ai Magazine*, 26(4), 53-53.
- Chen, Y., Fu, Q., Yuan, Y., Wen, Z., Fan, G., Liu, D., ... & Xiao, Y. (2023, October). Hallucination detection: Robustly discerning reliable answers in large language models. In *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management* (pp. 245-255).
- Cipolla, C. M., & Altan. (2015). *Le leggi fondamentali della stupidità umana*. Il mulino.
- Dechter, R. (1986). *Learning while searching in constraint-satisfaction problems*. <https://n9.cl/f8jd2>
- Dziri, N., Milton, S., Yu, M., Zaiane, O., & Reddy, S. (2022). *On the origin of hallucinations in conversational models: Is it the datasets or the models?* arXiv preprint arXiv:2204.07931
- Floridi, L. (2020). AI and its new winter: From myths to realities. *Philosophy & Technology*, 33, 1-3.
- Fradkov, A. L. (2020). Early history of machine learning. *IFAC-PapersOnLine*, 53(2), 1385-1390.
- Gugerty, L. (2006). Newell and Simon's logic theorist: Historical background and impact on cognitive modeling. In *Proceedings of the human factors and ergonomics society annual meeting* 50(9), 880-884). Sage CA. SAGE Publications.
- Hatem, R., Simmons, B., & Thornton, J. E. (2023). A Call to Address AI "Hallucinations" and How Healthcare Professionals Can Mitigate Their Risks. *Cureus*, 15(9).
- Haugeland, J. (1989). *Artificial intelligence: The very idea*. MIT press.
- IBM. (2024, April 11). *What are ai hallucinations?* <https://n9.cl/3tvd4>
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12), 1-38.
- Lee, K., Firat, O., Agarwal, A., Fannjiang, C., & Sussillo, D. (2018). Hallucinations in neural machine translation. <https://n9.cl/0s0vb>
- Li, Z. (2023). *The dark side of ChatGPT: legal and ethical challenges from stochastic parrots and hallucination*. arXiv preprint arXiv:2304.14347
- Luo, J., Li, T., Wu, D., Jenkin, M., Liu, S., & Dudek, G. (2024). *Hallucination Detection and Hallucination Mitigation: An Investigation*. arXiv preprint arXiv:2401.08358
- Merriam-Webster. (s. f.). Hallucination. In Merriam-Webster.com dictionary. Retrieved May 3, 2024, from <https://n9.cl/ay325n>
- Muthukrishnan, N., Maleki, F., Ovens, K., Reinhold, C., Forghani, B., & Forghani, R. (2020). Brief history of artificial intelligence. *Neuroimaging Clinics of North America*, 30(4), 393-399.
- Newell, A., & Shaw, J. C. (1959). A variety of intelligent learning in a general problem solver. *RAND Report*, p. 1742. <https://n9.cl/wy401>
- Olivetti, E. (s. f.). Online Latin dictionary - Latin - English. Latin Dictionary. *Olivetti Media Communication*. <https://n9.cl/pb4ft>
- Rawte, V., Sheth, A., & Das, A. (2023). *A survey of hallucination in large foundation models*. arXiv preprint arXiv:2309.05922
- Sah, S. (2020). *Machine learning: a review of learning types*. <https://doi.org/10.20944/preprints202007.0230.v1>
- Schmidhuber, J. (2022). *Annotated history of modern ai and deep learning*. arXiv preprint arXiv:2212.11279.
- Siegel, R. K. (1977) Hallucinations. *Scientific American*, 237(4), 132-141.
- Su, W., Wang, C., Ai, Q., Hu, Y., Wu, Z., Zhou, Y., & Liu, Y. (2024). Unsupervised real-time hallucination detection based on the internal states of large language models. arXiv preprint arXiv:2403.06448
- Venkit, P. N., Chakravorti, T., Gupta, V., Biggs, H., Srinath, M., Goswami, K., ... & Wilson, S. (2024). "Confidently Nonsensical?": A Critical Survey on the Perspectives and Challenges of 'Hallucinations' in NLP. arXiv preprint arXiv:2404.07461
- West, D. M., & Allen, J. R. (2018). *How artificial intelligence is transforming the world*. <https://n9.cl/ju4u5>
- Xiao, W., Huang, Z., Gan, L., He, W., Li, H., Yu, Z., ... & Zhu, L. (2024). *Detecting and Mitigating Hallucination in Large Vision Language Models via Fine-Grained AI Feedback*. arXiv preprint arXiv:2404.14233